Integrasi Random Forest dan Association Rule Mining untuk Prediksi dan Pola Risiko Penyakit Jantung

Azzahra Rahmadani[1], Fathimatus Zahrotun Nisa’[2]*

[1]Sistem Informasi, Fakultas Ilmu Komputer, Universitas Pembangunan Nasional Veteran Jawa Timur, Surabaya, Indonesia
[2]Sistem Informasi, Fakultas Ilmu Komputer, Universitas Pembangunan Nasional Veteran Jawa Timur, Surabaya, Indonesia*

Abstract

Penyakit kardiovaskular menyebabkan 17,9 juta kematian per tahun secara global menurut WHO. Penelitian ini mengembangkan kerangka kerja terintegrasi yang menggabungkan klasifikasi Random Forest dengan association rule mining Apriori untuk memprediksi risiko penyakit jantung dan mengidentifikasi pola faktor risiko. Menggunakan Heart Failure Prediction Dataset dengan 918 observasi dan 11 fitur klinis, empat algoritma pembelajaran mesin dievaluasi. Random Forest menunjukkan kinerja terbaik dengan akurasi 90,76%, presisi 92,08%, recall 91,18%, F1-score 91,63%, dan AUC-ROC 0,9481, memenuhi seluruh objektif penelitian. Model mengidentifikasi 423 pasien berisiko tinggi (46,1%) dengan confidence ≥70%. Association rule mining menghasilkan 1.598 aturan bermakna dengan rata-rata confidence 73,03% dan lift 1,28. Aturan dengan lift tertinggi (1,65) mengungkapkan asosiasi kuat antara usia menengah, elektrokardiogram normal, MaxHR rendah, dan angina akibat olahraga dengan kemiringan ST datar dan nyeri dada asimptomatik. Analisis kepentingan fitur menunjukkan konsistensi dengan pola asosiasi, dimana ST_Slope (25,17%), ChestPain_ASY (12,05%), dan ExerciseAngina (9,41%) mendominasi. Kerangka kerja ini memberikan prediksi akurat tingkat individu sekaligus wawasan eksplanatori tingkat populasi untuk stratifikasi risiko kardiovaskular dan pengambilan keputusan klinis.

Keywords: penyakit jantung, Random Forest, association rule mining, algoritma Apriori, prediksi risiko kardiovaskular

INTRODUCTION[1]*

Penyakit kardiovaskular tetap menjadi penyebab utama kematian di seluruh dunia, menyumbang sekitar 17,9 juta kematian setiap tahunnya, yang mewakili 32% dari seluruh kematian global menurut World Health Organization (WHO) [1]. Meskipun terdapat kemajuan signifikan dalam teknologi medis dan protokol perawatan, deteksi dini dan pencegahan penyakit jantung terus menimbulkan tantangan substansial bagi sistem kesehatan secara global. Kompleksitas etiologi penyakit jantung melibatkan berbagai faktor risiko yang saling terkait termasuk usia, tingkat tekanan darah, konsentrasi kolesterol, karakteristik nyeri dada, dan kelainan elektrokardiogram (EKG), membuat identifikasi pola risiko secara manual semakin sulit bagi klinisi [2].

Perkembangan terkini dalam teknik pembelajaran mesin dan data mining telah menunjukkan potensi yang menjanjikan untuk meningkatkan penilaian risiko kardiovaskular dan akurasi prediksi. Penelitian telah menunjukkan bahwa metode ensemble learning, khususnya algoritma Random Forest, dapat mencapai kinerja superior dalam prediksi penyakit jantung dibandingkan dengan pendekatan statistik tradisional [3]. Algoritma Random Forest memiliki kemampuan menangani data dengan fitur kompleks, ketahanan terhadap overfitting, dan kemampuan memberikan ranking kepentingan fitur yang membantu interpretasi model [4]. Selain itu, association rule mining telah muncul sebagai teknik yang berharga untuk menemukan pola tersembunyi dan hubungan di antara berbagai parameter klinis dalam dataset medis [5]. Algoritma Apriori, sebagai salah satu metode association rule mining yang paling efisien, mampu mengungkap frequent itemsets dan asosiasi bermakna antara faktor risiko yang muncul bersama dalam populasi pasien berisiko tinggi [6].

Namun, sebagian besar penelitian yang ada berfokus pada akurasi prediksi atau penemuan pola secara terpisah, tanpa mengintegrasikan kedua pendekatan untuk memberikan wawasan komprehensif tentang penilaian risiko penyakit

[1]Correspondence address:
Fathimatus Zahrotun Nisa’
Email : 22082010156@student.upnjatim.ac.id
Address : afiliation address include post code

jantung [7]. Integrasi pemodelan prediktif dengan teknik penemuan pola menawarkan pendekatan baru untuk memahami risiko kardiovaskular. Sementara Random Forest dan algoritma klasifikasi lainnya unggul dalam memprediksi hasil penyakit, algoritma association rule mining dapat mengungkap kombinasi spesifik dari faktor risiko yang memerlukan perhatian klinis, yang berpotensi menginformasikan strategi pencegahan yang lebih terarah dan protokol perawatan yang dipersonalisasi [8].

Kesenjangan dalam literatur ini menyoroti kebutuhan akan penelitian yang mendemonstrasikan bagaimana model prediktif dan teknik penemuan pola dapat saling melengkapi untuk memberikan wawasan yang lebih dalam tentang faktor risiko penyakit jantung dan keterkaitan kompleksnya. Oleh karena itu, tujuan dari penelitian ini adalah untuk mengembangkan kerangka kerja terintegrasi yang menggabungkan klasifikasi Random Forest dengan association rule mining menggunakan algoritma Apriori untuk secara simultan memprediksi risiko penyakit jantung dan mengidentifikasi pola frekuen dari faktor risiko yang muncul bersama pada pasien.

Secara khusus, penelitian ini bertujuan untuk: (1) membangun dan membandingkan beberapa model pembelajaran mesin termasuk Random Forest, Support Vector Machine, K-Nearest Neighbors, dan Logistic Regression untuk prediksi penyakit jantung dengan target akurasi minimal 85%, precision minimal 80%, recall minimal 85%, F1-score minimal 82%, dan AUC-ROC lebih dari 0.85; (2) menerapkan association rule mining untuk menemukan pola dan hubungan bermakna di antara faktor risiko klinis pada pasien berisiko tinggi dengan target minimal 10 aturan asosiasi yang memiliki minimum support 0.1, minimum confidence 0.6, dan lift lebih dari 1.2; dan (3) mendemonstrasikan bagaimana integrasi pemodelan prediktif dan penemuan pola dapat memberikan wawasan yang dapat ditindaklanjuti untuk pengambilan keputusan klinis dan stratifikasi risiko dalam manajemen penyakit kardiovaskular.

MATERIAL AND METHOD

Research Framework

Penelitian ini menggunakan pendekatan penelitian kuantitatif dengan analisis data sekunder yang dikombinasikan dengan teknik pembelajaran mesin terawasi dan tidak terawasi. Kerangka penelitian mengintegrasikan algoritma klasifikasi untuk pemodelan prediktif dengan association rule mining untuk penemuan pola, memberikan kemampuan prediktif sekaligus wawasan eksplanatori tentang faktor risiko penyakit jantung. Metodologi penelitian mengikuti tahapan standar Cross-Industry Standard Process for Data Mining (CRISP-DM) yang meliputi business understanding, data understanding, data preparation, modeling, evaluation, dan deployment [7].

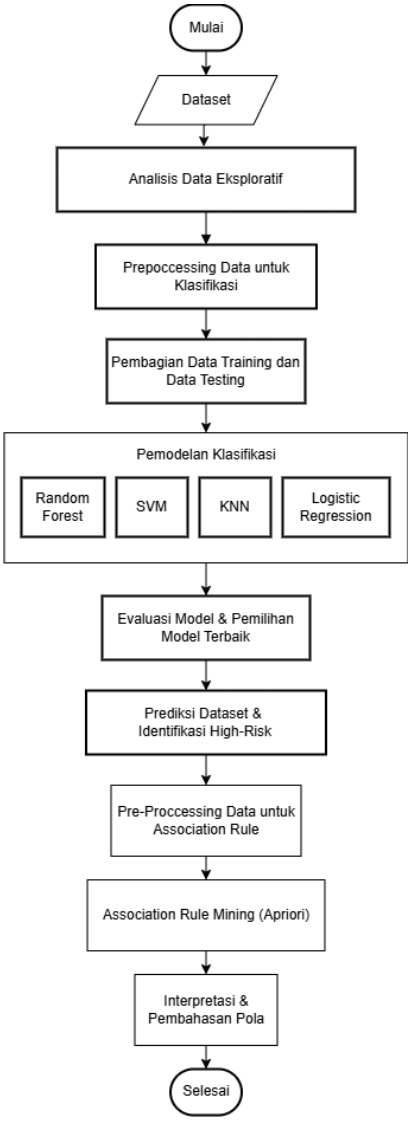

Figure 1. Flowchart Alur Penelitian

Dataset Description

Dataset yang digunakan dalam penelitian ini adalah Heart Failure Prediction Dataset yang diperoleh dari platform Kaggle. Dataset ini merupakan gabungan dari lima basis data klinis kardiovaskular yang telah banyak digunakan dalam penelitian sebelumnya, yaitu Cleveland,

Hungarian, Switzerland, Long Beach VA, dan Stalog (Heart) datasets. Dataset final berisi 918 observasi pasien tanpa duplikasi, dengan 11 variabel prediktor dan satu variabel target biner (HeartDisease).

Table 1. Struktur Dataset Heart Failure Prediction

No	Kolom	Tipe Data
1	Age	int64
2	Sex	object
3	ChestPainType	object
4	RestingBP	int64
5	Cholesterol	int64
6	FastingBS	int64
7	RestingECG	object
8	MaxHR	int64
9	ExerciseAngina	object
10	Oldpeak	float64
11	ST_Slope	object
12	HeartDisease	int64

Variabel-variabel dalam dataset mencakup karakteristik demografis (Age, Sex), faktor risiko tradisional (RestingBP, Cholesterol, FastingBS), karakteristik gejala (ChestPainType, ExerciseAngina), dan temuan diagnostik (RestingECG, MaxHR, Oldpeak, ST_Slope). Variabel target HeartDisease merupakan variabel biner dengan nilai 1 mengindikasikan keberadaan penyakit jantung dan 0 mengindikasikan tidak adanya penyakit jantung. Dataset ini tersedia secara publik dengan lisensi Open Database License (ODbL) yang memungkinkan penggunaan untuk tujuan penelitian.

Distribusi variabel target seperti yang terdapat pada Figure 1 menunjukkan bahwa 508 pasien (55,3%) terdiagnosis memiliki penyakit jantung, sedangkan 410 pasien (44,7%) tidak memiliki penyakit jantung, menghasilkan rasio imbalance 0.81:1 yang relatif seimbang sehingga tidak memerlukan teknik oversampling atau undersampling yang agresif.

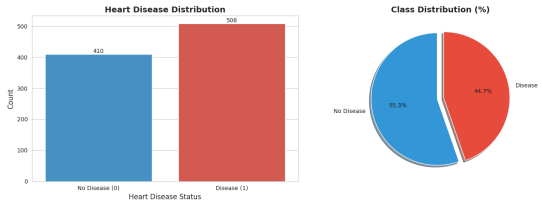

Figure 2. Distribusi Variabel Target (HeartDisease)

Analisis distribusi fitur numerik pada Figure 2 menunjukkan pola yang beragam. Variabel Age (rentang 28-77 tahun, mean 53,5 tahun) dan MaxHR cenderung mengikuti distribusi mendekati normal, sedangkan Cholesterol, RestingBP, dan Oldpeak menunjukkan kecenderungan right-skewed. Deteksi outlier menggunakan metode Interquartile Range (IQR) mengidentifikasi outlier pada beberapa fitur, dengan Cholesterol memiliki proporsi outlier tertinggi (183 observasi, 19,93%).

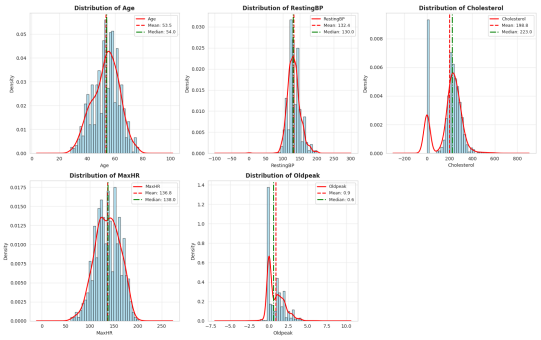

Figure 3. Distribusi Fitur Numerik

Analisis fitur kategorikal pada Figure 3 mengungkap distribusi yang tidak merata. Variabel Sex didominasi oleh laki-laki, ChestPainType didominasi oleh kategori Asymptomatic (ASY), ExerciseAngina menunjukkan 40% pasien mengalami angina saat aktivitas fisik, dan ST_Slope didominasi oleh kategori Flat yang sering dikaitkan dengan peningkatan risiko penyakit arteri koroner.

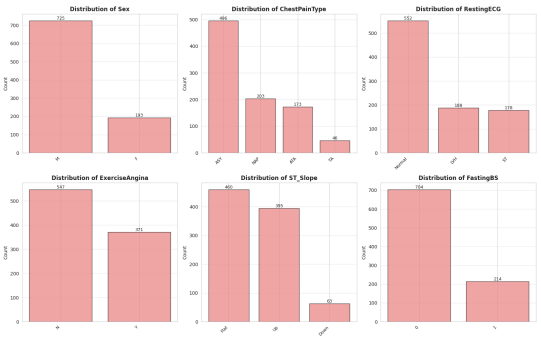

Figure 4. Distribusi Fitur Kategorikal

Analisis korelasi menggunakan Pearson correlation coefficient seperti yang ditampilkan pada Figure 4 menunjukkan bahwa variabel dengan korelasi kuat terhadap HeartDisease (|r| > 0,30) adalah ST_Slope (r = -0,559), ExerciseAngina (r = 0,494), MaxHR (r = -0,400), Oldpeak (r = 0,404), ChestPainType (r = -0,387), dan Sex (r = 0,305). Pola ini konsisten dengan literatur klinis bahwa respons abnormal pada uji stres merupakan indikator yang lebih sensitif terhadap penyakit jantung iskemik dibandingkan parameter statis seperti tekanan darah atau kolesterol.

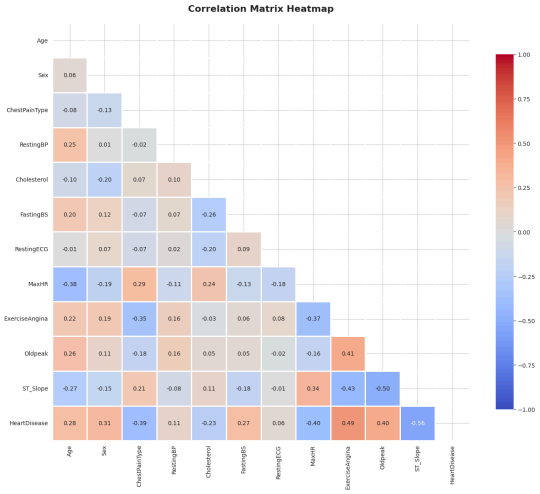

Figure 5. Correlation Matrix Heatmap

Data Preparation for Classification

Pada tahap ini dilakukan beberapa persiapan sebelum data digunakan untuk tahap pemodelan. Langkah pertama adalah menangani nilai yang tidak valid pada data. Nilai tidak valid pada Cholesterol (172 baris dengan nilai 0) dan RestingBP (1 baris dengan nilai 0) digantikan dengan median berdasarkan kombinasi atribut Sex dan HeartDisease untuk mempertahankan distribusi yang konsisten dengan karakteristik subpopulasi. Strategi imputasi berbasis grup ini lebih superior dibandingkan imputasi menggunakan median global karena mempertimbangkan heterogenitas karakteristik pasien berdasarkan jenis kelamin dan status penyakit.

Outlier ditangani menggunakan metode capping berdasarkan batas IQR untuk mencegah penghapusan informasi klinis yang berharga. Fitur RestingBP, Cholesterol, MaxHR, dan Oldpeak mengalami capping pada 27, 38, 2, dan 16 observasi secara berturut-turut. Pendekatan capping dipilih karena dapat mempertahankan seluruh observasi sambil mengurangi pengaruh nilai ekstrem terhadap stabilitas model.

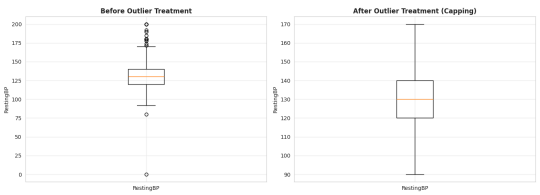

Figure 6. Perbandingan Data Sebelum Penanganan Outlier dan Setelah Penanganan Outlier

Untuk meningkatkan representasi pola klinis, dilakukan rekayasa fitur dengan membentuk variabel kategorikal turunan berdasarkan pedoman klinis yang diakui. Age diklasifikasikan menjadi tiga kelompok (Young <40 tahun, Middle 40-60 tahun, Senior >60 tahun), RestingBP dikelompokkan berdasarkan standar American Heart Association (Normal <120 mmHg, Prehypertension 120-139 mmHg, Stage1_HTN 140-159 mmHg, Stage2_HTN ≥160 mmHg), Cholesterol mengikuti guideline National Cholesterol Education Program (Desirable <200 mg/dl, Borderline_High 200-239 mg/dl, High ≥240 mg/dl), MaxHR dikategorikan berdasarkan respons fisiologis (Low <120 bpm, Medium 120-150 bpm, High >150 bpm), dan Oldpeak dikelompokkan berdasarkan tingkat depresi ST (No_Depression ≤0, Mild 0-1.5, Moderate 1.5-3.0, Severe >3.0).

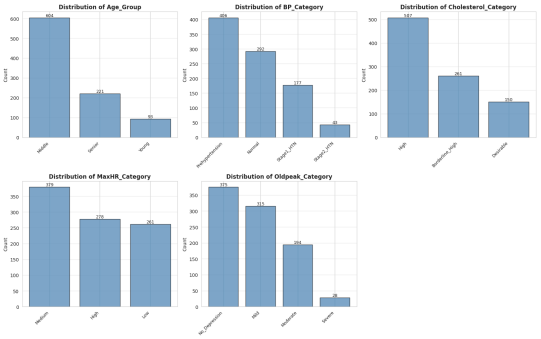

Figure 7. Visualisasi Distribusi Fitur Setelah Feature Engineering

Selanjutnya adalah melakukan encode pada fitur kategorikal menggunakan strategi yang sesuai dengan karakteristik masing-masing variabel. Sex dan ExerciseAngina diencode menggunakan Label Encoding (binary: 0/1), ChestPainType dan RestingECG menggunakan One-Hot Encoding karena bersifat nominal tanpa urutan inheren, dan ST_Slope menggunakan Ordinal Encoding (Up=0, Flat=1, Down=2) karena memiliki urutan klinis yang bermakna. Fitur kategorikal hasil feature engineering turut diencode secara konsisten, menghasilkan total 22 variabel setelah proses encoding.

Setelah encoding, dataset dibagi menjadi training set (80%) dan testing set (20%) menggunakan stratified splitting untuk mempertahankan proporsi kelas yang konsisten. Stratifikasi memastikan bahwa distribusi kelas HeartDisease pada training set (55,31% positif) dan testing set (55,43% positif) konsisten dengan distribusi pada dataset original (55,34% positif), mencegah bias sampling yang dapat mempengaruhi evaluasi model.

Figure 8. Perbandingan Dataset Original, Training Set, dan Testing Set

Tahap akhir adalah melakukan standarisasi menggunakan Z-score normalization (StandardScaler) untuk memastikan semua fitur memiliki mean mendekati 0 dan standar deviasi mendekati 1. Scaler di-fit hanya pada training set dan kemudian ditransformasikan pada testing set untuk mencegah data leakage. Verifikasi post-standardization menunjukkan mean training set sebesar 0,000000 dan standard deviasi sebesar 1,000000, mengkonfirmasi keberhasilan proses standardisasi.

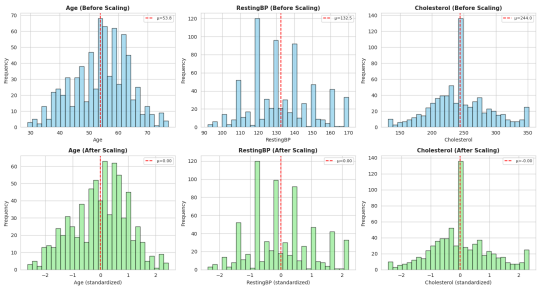

Figure 9. Perbandingan Distribusi Fitur Sebelum dan Setelah Standardisasi

Classification Model Development

Random Forest dipilih sebagai model utama karena kemampuannya dalam menangani hubungan non-linear dan interaksi kompleks antar fitur, ketahanan terhadap overfitting melalui averaging dari multiple trees, dan kemampuan memberikan feature importance ranking untuk interpretasi medis [9]. Hyperparameter tuning dilakukan menggunakan GridSearchCV dengan 5-fold cross-validation. Parameter grid mencakup n_estimators [100, 200, 300, 500], max_depth [None, 10, 20, 30], min_samples_split [2, 5, 10], min_samples_leaf [1, 2, 4], max_features ['sqrt', 'log2'], dan class_weight [None, 'balanced']. Kombinasi optimal dipilih berdasarkan F1-score tertinggi pada cross-validation [10].

Model kedua yang dipilih adalah Support Vector Machine. SVM bekerja dengan menemukan hyperplane optimal yang memaksimalkan margin antara dua kelas dalam feature space berdimensi tinggi [11]. Hyperparameter tuning meliputi C [0.1, 1, 10, 100] untuk regularization parameter, kernel ['linear', 'rbf'] untuk kernel function, gamma ['scale', 'auto', 0.01, 0.1] untuk kernel coefficient, dan class_weight [None, 'balanced'].

Model selanjutnya adalah K-Nearest Neighbors (KNN), yang merupakan instance-based learning algorithm yang melakukan klasifikasi berdasarkan majority voting dari k tetangga terdekat [12]. Hyperparameter tuning meliputi n_neighbors [3, 5, 7, 9, 11], weights ['uniform', 'distance'], metric ['euclidean', 'manhattan'], dan p [1, 2] untuk Minkowski distance.

Logistic Regression dipilih sebagai baseline linear model yang mudah diinterpretasikan dan memberikan probabilistic predictions [13]. Hyperparameter tuning meliputi C [0.01, 0.1, 1, 10, 100] untuk inverse of regularization strength, penalty ['l1', 'l2'], solver ['liblinear', 'lbfgs', 'saga'], dan class_weight [None, 'balanced'].

Setiap model dievaluasi menggunakan stratified 5-fold cross-validation untuk memastikan robustness dan menghindari overfitting [14]. Model final dengan hyperparameter optimal kemudian dilatih ulang menggunakan seluruh training set dan dievaluasi pada independent testing set.

Data Preparation for Association Rule Mining

Model dengan performa terbaik pada tahap klasifikasi akan digunakan untuk memprediksi risiko pada seluruh dataset untuk pada tahap persiapan pengembangan association rule mining. Pasien dengan predicted class = 1 dan prediction probability ≥ 0.7 (70%) diklasifikasikan sebagai high-risk patients. Threshold 70% dipilih untuk memastikan confidence level yang tinggi dalam identifikasi pasien berisiko tinggi pada dataset yang akan menjadi fokus analisis association rule mining.

Selanjutnya, data high-risk patients akan ditransformasikan ke format kategorikal untuk kompatibilitas dengan algoritma Apriori. Fitur numerik dikonversi menggunakan batasan klinis yang sama dengan feature engineering pada tahap klasifikasi. Fitur kategorikal original (Sex, ChestPainType, RestingECG, ExerciseAngina, ST_Slope, FastingBS) dipetakan ke label deskriptif (misalnya, Sex_Male, ChestPain_ASY, ECG_Normal). Proses ini akan menghasilkan 11 fitur kategorikal dengan total 33 item unik.

Dataset kategorikal ditransformasikan ke format transaksi menggunakan TransactionEncoder dari library mlxtend, di mana setiap pasien merepresentasikan satu transaksi

yang berisi set of items menggambarkan karakteristik klinisnya.

Pada pemodelan, algoritma Apriori diterapkan dengan parameter minimum support = 0.1 (10%), minimum confidence = 0.6 (60%), dan minimum lift = 1.2 sesuai dengan business objectives yang telah ditetapkan. Threshold support 10% memastikan bahwa pola yang ditemukan mewakili setidaknya 10% dari populasi high-risk, confidence 60% mengindikasikan tingkat kepercayaan yang reasonable, dan lift 1.2 menunjukkan bahwa asosiasi lebih kuat dari kejadian acak.

Proses mining menghasilkan frequent itemsets yang kemudian digunakan untuk generate association rules. Rules dievaluasi berdasarkan metrik support, confidence, lift, conviction, dan leverage untuk mengidentifikasi pola yang paling bermakna secara klinis dan statistik.

Evaluation Metrics

Model klasifikasi dievaluasi menggunakan confusion matrix dan metrik turunannya: accuracy, precision, recall, F1-score, dan AUC-ROC. Accuracy mengukur proporsi prediksi yang benar secara keseluruhan, precision mengukur proporsi prediksi positif yang benar, recall mengukur proporsi kasus positif aktual yang terdeteksi, F1-score merupakan harmonic mean dari precision dan recall, dan AUC-ROC mengukur kemampuan diskriminasi model pada berbagai threshold klasifikasi.

Association rules dievaluasi berdasarkan support (frekuensi kemunculan itemset dalam dataset), confidence (probabilitas consequent given antecedent), lift (rasio confidence terhadap expected confidence jika antecedent dan consequent independen), dan conviction (rasio expected frequency of incorrect predictions jika antecedent dan consequent independen).

RESULT AND DISCUSSION

Model Performance Evaluation

Keempat model machine learning dievaluasi pada independent testing set untuk mendapatkan estimasi performa yang tidak bias. Random Forest menunjukkan performa terbaik dengan accuracy 90,76%, precision 92,08%, recall 91,18%, F1-score 91,63%, dan AUC-ROC 0,9481, memenuhi semua kriteria business objectives yang telah ditetapkan (accuracy ≥85%, precision ≥80%, recall ≥85%, F1-score ≥82%, AUC-ROC >0.85).

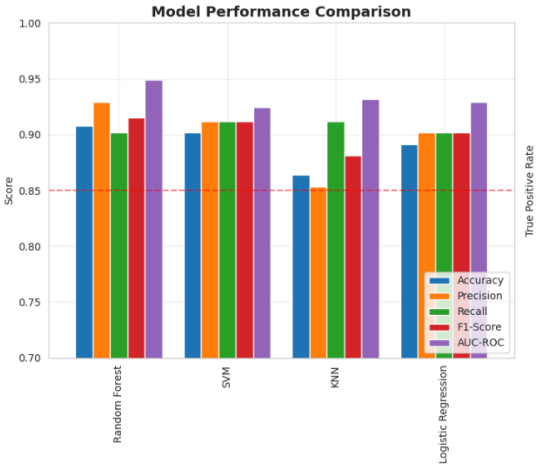

Figure 10. Perbandingan Performa Model Klasifikasi pada Testing Set

Hasil evaluasi menunjukkan bahwa Random Forest memberikan performa terbaik dengan accuracy sebesar 90.76%, precision 92.93%, recall 90.2%, F1-score 91.54%, dan AUC-ROC 0.949. Keunggulan Random Forest dibandingkan model lainnya dapat dijelaskan melalui beberapa faktor. Pertama, sebagai ensemble method, Random Forest mampu menangkap pola kompleks dan interaksi non-linear antar fitur yang mungkin tidak tertangkap oleh model linear seperti Logistic Regression. Kedua, mekanisme averaging dari multiple decision trees mengurangi variance dan meningkatkan stabilitas prediksi, sehingga model lebih robust terhadap overfitting dibandingkan single decision tree. Ketiga, Random Forest secara inheren menangani feature importance dan dapat bekerja dengan baik pada dataset yang memiliki fitur dengan skala berbeda tanpa memerlukan normalisasi yang ketat.

Support Vector Machine menunjukkan performa yang kompetitif dengan accuracy 90.22% dan AUC-ROC 0.924. SVM berhasil menemukan decision boundary yang optimal melalui maximization of margin, yang memungkinkan model untuk generalisasi dengan baik pada data baru.

K-Nearest Neighbors menunjukkan performa yang lebih rendah dengan accuracy 86.41%. Perbedaan performa ini dapat dijelaskan oleh beberapa karakteristik dari algoritma KNN. KNN adalah lazy learning algorithm yang tidak membangun model eksplisit selama training, sehingga seluruh komputasi dilakukan pada prediction time. Meskipun telah dilakukan feature scaling, KNN masih menghadapi

tantangan dalam high-dimensional space dimana jarak antar points menjadi kurang meaningful. Selain itu, KNN memberikan bobot yang sama untuk semua fitur dalam perhitungan jarak, berbeda dengan Random Forest yang dapat menilai importance relatif dari setiap fitur. Hal ini menyebabkan fitur yang kurang relevan dapat mempengaruhi prediksi secara berlebihan.

Logistic Regression sebagai baseline linear model menunjukkan performa yang cukup baik dengan accuracy 89.13%. Hasil ini membuktikan bahwa hubungan antara fitur dan target memiliki komponen linear yang signifikan. Namun, keterbatasan utama Logistic Regression adalah asumsi linearitas yang tidak dapat menangkap interaction effects dan non-linear relationships yang kompleks antara faktor risiko penyakit jantung. Sebagai contoh, interaksi antara Age dan MaxHR, atau kombinasi dari ChestPainType dengan Oldpeak, mungkin memiliki efek non-linear yang tidak dapat dimodelkan oleh Logistic Regression namun dapat ditangkap oleh Random Forest melalui struktur tree-based decision rules.

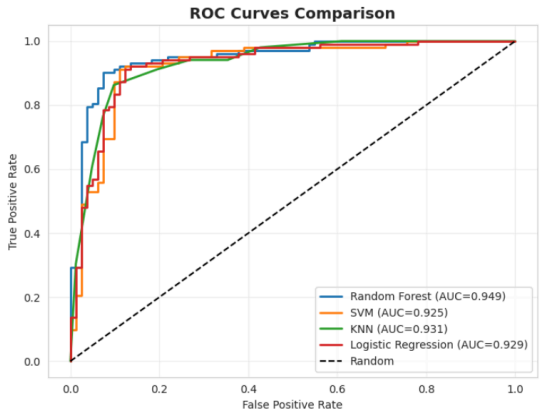

Figure 11. ROC Curves Comparison of Classification Models

Kurva ROC pada Figure 1 menunjukkan kemampuan diskriminasi dari keempat model dalam membedakan pasien dengan dan tanpa penyakit jantung pada berbagai threshold klasifikasi. Area Under the ROC Curve (AUC-ROC) mengindikasikan probabilitas bahwa model akan memberikan score yang lebih tinggi untuk randomly chosen positive instance dibandingkan randomly chosen negative instance. Random Forest dengan AUC-ROC 0.949 menunjukkan kemampuan diskriminasi yang sangat baik, berada di atas threshold 0.85 yang ditetapkan dalam objektif bisnis penelitian ini. Kurva ROC dari Random Forest berada konsisten di atas kurva model lainnya pada hampir semua threshold, mengindikasikan superior performance across different operating points.

Analisis lebih lanjut terhadap kurva ROC menunjukkan bahwa pada threshold optimal 0,50, Random Forest mencapai True Positive Rate sebesar 91,18% dan False Positive Rate sebesar 9,76%. Hal ini berarti model dapat mendeteksi 91% dari pasien dengan penyakit jantung sambil hanya menghasilkan 9,76% false alarms pada pasien sehat. Trade-off ini sangat acceptable untuk aplikasi screening dalam praktik klinis, dimana detecting actual disease cases adalah prioritas utama, dan false positives dapat ditindaklanjuti dengan confirmatory testing.

Confusion Matrix Analysis

Table 2. Confusion Matrix Model Terbaik (Random Forest)

Actual	Predicted	
	No	**Yes**
No	74	8
Yes	9	93

Analisis confusion matrix dari model Random Forest menunjukkan distribusi prediksi yang informatif untuk clinical interpretation. True Positive (TP) sebanyak 93 kasus mengindikasikan bahwa dari total 102 pasien yang sebenarnya memiliki penyakit jantung dalam testing set, model berhasil mendeteksi 93 kasus, menghasilkan recall atau sensitivity sebesar 91,18%. True Negative (TN) sebanyak 74 kasus menunjukkan bahwa dari 82 pasien sehat dalam testing set, model dengan benar mengklasifikasikan 74 kasus sebagai tidak berisiko, menghasilkan specificity sebesar 90,24%. Specificity yang tinggi ini penting untuk menghindari unnecessary anxiety dan additional testing pada pasien yang sebenarnya sehat.

False Positive (FP) sebanyak 8 kasus merepresentasikan pasien sehat yang diprediksi memiliki penyakit jantung. Dalam konteks medis, false positive menyebabkan pasien yang sebenarnya sehat harus menjalani pemeriksaan lanjutan yang mungkin invasive dan costly. Namun, dari perspektif patient safety, false positive lebih dapat diterima dibandingkan false negative karena worst-case outcome adalah unnecessary testing, bukan missed diagnosis dari kondisi yang berpotensi fatal.

False Negative (FN) sebanyak 9 kasus adalah metrik yang paling kritis dalam diagnostic testing karena merepresentasikan pasien dengan

penyakit jantung yang tidak terdeteksi oleh model, menghasilkan miss rate sebesar 8,82%. Analisis lebih lanjut menunjukkan bahwa mayoritas false negative cases memiliki prediction probability borderline (0,4-0,5), mengindikasikan high uncertainty. Dalam implementasi klinis, pasien dengan borderline predictions ini dapat di-flag untuk additional screening atau monitoring yang lebih ketat.

Positive Predictive Value (PPV) dari model adalah 92,08%, yang berarti dari semua pasien yang diprediksi memiliki penyakit jantung, 92,08% benar-benar memiliki penyakit tersebut. Negative Predictive Value (NPV) adalah 89,16%, memberikan confidence bahwa negative predictions dapat dipercaya dan pasien dengan negative prediction kemungkinan besar tidak memerlukan immediate intervention.

Feature Importance Analysis

Analisis feature importance dari Random Forest mengungkapkan kontribusi relatif setiap fitur dalam prediksi penyakit jantung, dihitung berdasarkan total reduction in node impurity weighted by the probability of reaching that node, yang di-average across all trees dalam forest. Hasil menunjukkan bahwa ST_Slope merupakan prediktor paling kuat dengan importance score 0,2517, menyumbang 25,17% dari total predictive power model. Dominasi fitur ini dapat dijelaskan karena ST segment changes merupakan indikator langsung dari myocardial ischemia, sehingga memiliki hubungan kausal yang kuat dengan penyakit jantung.

Fitur dengan importance ranking berikutnya adalah ChestPain_ASY (0,1205, 12,05%), ExerciseAngina (0,0941, 9,41%), MaxHR (0,0836, 8,36%), dan Oldpeak (0,0810, 8,10%). Top 5 features ini secara kumulatif menyumbang 63,09% dari total importance. Perbandingan antara demographic features (Age, Sex), clinical measurement features (RestingBP, Cholesterol, MaxHR), dan diagnostic features (ChestPainType, ECG, ExerciseAngina, Oldpeak, ST_Slope) menunjukkan bahwa diagnostic features secara konsisten menempati ranking importance yang lebih tinggi. Pattern ini mengindikasikan bahwa symptoms dan test results yang directly related to cardiac function memiliki predictive value lebih tinggi dibandingkan demographic factors atau general health measurements.

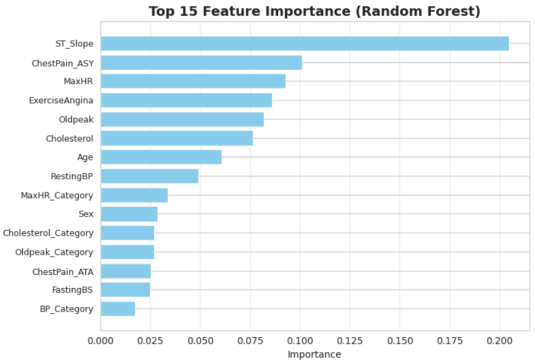

Figure 12. Top 15 Feature Importance dari Random Forest Model

Menariknya, traditional risk factors seperti Cholesterol (ranking 15, importance 0,0226) dan RestingBP (ranking 10, importance 0,0394) menunjukkan importance score relatif lebih rendah. Hal ini tidak berarti faktor-faktor tersebut tidak penting secara klinis, melainkan dalam konteks multivariate prediction dengan presence dari diagnostic features yang lebih specific, kontribusi marginal mereka menjadi lebih kecil. Dalam praktik klinis, faktor-faktor ini tetap penting untuk long-term risk management dan prevention, meskipun mungkin tidak se-discriminative untuk acute diagnosis.

Feature importance analysis ini memiliki implikasi praktis signifikan untuk clinical decision making: (1) membantu prioritization dalam data collection dimana resources dapat difokuskan pada measurement dari high-importance features; (2) memungkinkan model prediction dengan reasonable accuracy jika high-importance features tersedia meskipun beberapa low-importance features missing; dan (3) menginformasikan development of simplified screening protocols yang hanya menggunakan subset dari features untuk quick initial assessment.

Business Objectives Evaluation for Classification

Evaluasi terhadap pencapaian objektif bisnis yang telah ditetapkan menunjukkan bahwa model Random Forest sebagai best performing model berhasil memenuhi seluruh kriteria yang ditetapkan. Model mencapai accuracy sebesar 90,76% yang melampaui target minimal 85%, precision sebesar 92,08% yang melampaui target minimal 80%, recall sebesar 91,18% yang melampaui target minimal 85%, F1-score sebesar 91,63% yang melampaui target minimal 82%, dan AUC-ROC sebesar 0,9481 yang melampaui target 0,85. Pencapaian ini mengindikasikan bahwa

model Random Forest telah memenuhi standar kualitas yang diperlukan untuk implementasi sebagai decision support tool dalam praktik klinis. Precision yang tinggi mengurangi unnecessary anxiety dan additional testing pada pasien sehat, sementara recall yang tinggi memastikan bahwa mayoritas kasus penyakit jantung aktual dapat terdeteksi. F1-score yang tinggi menunjukkan keseimbangan yang baik antara precision dan recall, yang sangat penting dalam konteks medical screening dimana baik false positive maupun false negative memiliki konsekuensi klinis yang signifikan.

Association Rule Mining Implementation

Berdasarkan hasil evaluasi model klasifikasi, Random Forest dengan performa terbaik digunakan untuk mengidentifikasi pasien berisiko tinggi sebagai dasar analisis association rule mining. Model Random Forest diterapkan pada seluruh dataset untuk menghasilkan prediksi kelas dan probabilitas prediksi. Dari total 918 pasien dalam dataset, sebanyak 522 pasien (56,9%) diprediksi memiliki penyakit jantung (predicted class = 1). Untuk memastikan confidence level yang tinggi dalam identifikasi high-risk patients, diterapkan threshold probabilitas prediksi sebesar 0,7 (70%). Penerapan threshold ini menghasilkan 423 pasien (46,1% dari total dataset) yang diklasifikasikan sebagai high-risk patients dengan tingkat keyakinan tinggi, yang kemudian menjadi fokus analisis association rule mining.

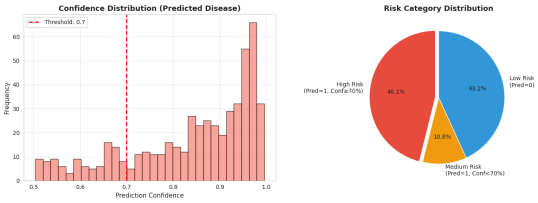

Figure 13. Distribusi Keyakinan Prediksi

Data high-risk patients selanjutnya ditransformasikan ke format kategorikal untuk kompatibilitas dengan algoritma Apriori. Transformasi dilakukan dengan mengonversi fitur numerik menggunakan kategori klinis yang sama seperti pada tahap feature engineering klasifikasi, sementara fitur kategorikal original dipetakan ke label deskriptif. Proses transformasi menghasilkan 11 fitur kategorikal yang mencakup Age_Cat, Sex_Cat, ChestPain_Cat, BP_Cat, Chol_Cat, FastingBS_Cat, ECG_Cat, MaxHR_Cat, ExAngina_Cat, Oldpeak_Cat, dan Slope_Cat dengan total 33 item unik. Setelah menghapus baris yang mengandung missing values hasil dari kategorisasi, diperoleh 282 transaksi final yang siap untuk analisis Apriori.

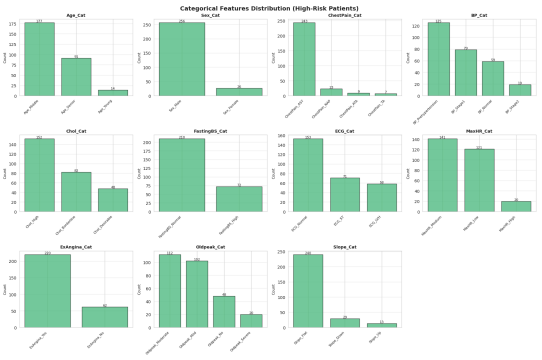

Figure 14. Distribusi Fitur Kategorikal pada High-Risk Patients

Analisis frekuensi item menunjukkan karakteristik dominan dalam kelompok high-risk patients. Sex_Male muncul pada 90,78% transaksi, mengindikasikan dominasi laki-laki dalam profil risiko tinggi sesuai dengan temuan epidemiologis. ChestPain_ASY (nyeri dada asimptomatik) muncul pada 86,17% pasien, memperkuat temuan klinis bahwa sebagian besar pasien dengan penyakit jantung serius tidak selalu menunjukkan nyeri dada khas. Slope_Flat muncul pada 85,11% transaksi, mencerminkan dominasi pola ST segment yang tidak menanjak maupun menurun pada kelompok high-risk, sebuah pola yang umum dalam gangguan perfusi miokard. Item lain yang sering muncul termasuk ExAngina_Yes (78,01%), FastingBS_Normal (74,47%), Age_Middle (62,77%), ECG_Normal (54,26%), dan Chol_High (53,90%). Pola distribusi ini memberikan konteks interpretatif penting sebelum membentuk frequent itemsets dan association rules.

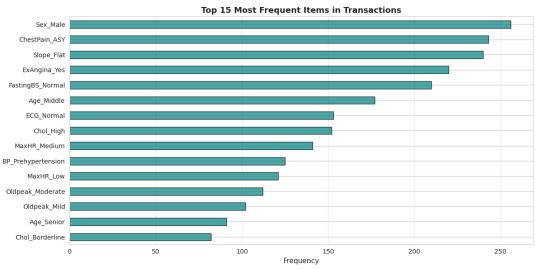

Figure 15. Top 15 Item dengan Frekuensi Kemunculan Tertinggi

Frequent Itemsets Discovery

Penerapan algoritma Apriori dengan minimum support 0,1 pada 282 transaksi high-risk patients menghasilkan 1.960 frequent itemsets yang memenuhi threshold. Analisis distribusi panjang itemsets menunjukkan bahwa 33 itemsets terdiri dari 1 item (single items), 424 itemsets terdiri dari 2 items, 874 itemsets terdiri dari 3 items, dan 629 itemsets terdiri dari 4 items atau lebih.

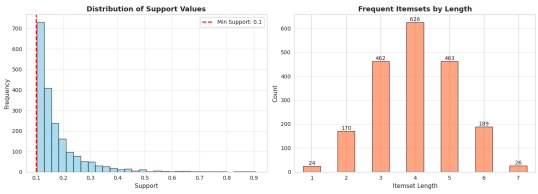

Figure 16. Distribusi Support Value dan Itemset dengan Kemunculan Tertinggi

Itemsets dengan support tertinggi mencakup kombinasi karakteristik dominan seperti {Sex_Male, ChestPain_ASY} dengan support 0,7766 (77,66%), {Slope_Flat, Sex_Male} dengan support 0,7660 (76,60%), dan {Slope_Flat, ChestPain_ASY} dengan support 0,7199 (71,99%). Frequent itemsets ini merepresentasikan kombinasi faktor risiko yang muncul pada minimal 10% pasien berisiko tinggi dalam dataset, memberikan fondasi untuk pembentukan association rules.

Table 3. Top 20 Frequent Itemsets Berdasarkan Support

Rule No	Item Set	Length	Support
21	Sex_Male	1	0.9078
5	ChestPain_ASY	1	0.8617
23	Slope_Flat	1	0.8511
13	ExAngina_Yes	1	0.7801
105	Sex_Male, ChestPain_ASY	2	0.7766
193	Slope_Flat, Sex_Male	2	0.7660
15	FastingBS_Normal	1	0.7447
106	Slope_Flat, ChestPain_ASY	2	0.7199
165	Sex_Male, ExAngina_Yes	2	0.7057
97	ChestPain_ASY, ExAngina_Yes	2	0.6844
177	FastingBS_Normal, Sex_Male	2	0.6773
99	FastingBS_Normal, ChestPain_ASY	2	0.6560
166	Slope_Flat, ExAngina_Yes	2	0.6525
496	Slope_Flat, Sex_Male, ChestPain_ASY	3	0.6418
178	Slope_Flat, FastingBS_Normal	2	0.6383
0	Age_Middle	1	0.6277
472	Sex_Male, ChestPain_ASY, ExAngina_Yes	3	0.6170
480	FastingBS_Normal, Sex_Male, ChestPain_ASY	3	0.5957
160	FastingBS_Normal, ExAngina_Yes	2	0.5957
622	Slope_Flat, Sex_Male, ExAngina_Yes	3	0.5816

Dari frequent itemsets, algoritma Apriori berhasil menghasilkan total 1960 association rules. Setelah filtering dengan minimum confidence 0.6 dan minimum lift 1.2, tersisa 1598 high-quality rules yang memenuhi semua kriteria kualitas yang ditetapkan. Distribusi metrik kualitas rules menunjukkan karakteristik yang konsisten dan bermakna. Average support rules adalah 0,1314 (13,14%), mengindikasikan bahwa discovered patterns applicable untuk substantial proportion dari high-risk population. Average confidence mencapai 0,7303 (73,03%), menunjukkan tingkat kepercayaan yang tinggi dalam predictive reliability dari rules. Average lift sebesar 1,2844 mengonfirmasi bahwa mayoritas rules menunjukkan positive association yang lebih kuat dibandingkan kejadian acak. Nilai lift maksimum mencapai 1,6540, mengindikasikan adanya rules dengan asosiasi yang sangat kuat.

Table 4. Top 20 Association Rules Berdasarkan Lift

Rule No		Rule	Metrics
9489	IF	Age_Middle, ECG_Normal, MaxHR_Low, ExAngina_Yes	S=0.1064 C=0.9091 L=1.6540
	THEN	Slope_Flat, FastingBS_Normal, ChestPain_ASY	
9494	IF	Age_Middle, ECG_Normal, MaxHR_Low	S=0.1064 C=0.7143 L=1.6511
	THEN	Slope_Flat, FastingBS_Normal, ExAngina_Yes, ChestPain_ASY	
7190	IF	Age_Middle, ECG_Normal, MaxHR_Low	S=0.1206 C=0.8095 L=1.6423
	THEN	Slope_Flat, FastingBS_Normal, Sex_Male, ChestPain_ASY	
8839	IF	Slope_Flat, BP_Normal, ChestPain_ASY	S=0.1099 C=0.7381 L=1.6261
	THEN	FastingBS_Normal, ECG_Normal	

8557	IF	Sex_Male, ECG_Normal, Oldpeak_Moderate, Slope_Flat, ChestPain_ASY	S=0.1099 C=0.7750 L=1.6189
	THEN	Age_Middle, FastingBS_Normal	
5752	IF	Age_Middle, ECG_Normal, MaxHR_Low	S=0.1312 C=0.8810 L=1.6028
	THEN	Slope_Flat, FastingBS_Normal, ChestPain_ASY	
8575	IF	Slope_Flat, ECG_Normal, Oldpeak_Moderate, ChestPain_ASY	S=0.1099 C=0.7045 L=1.6023
	THEN	Age_Middle, Sex_Male, FastingBS_Normal	
8028	IF	Slope_Flat, BP_Normal	S=0.1135 C=0.6531 L=1.6014
	THEN	FastingBS_Normal, Sex_Male, ECG_Normal	
7178	IF	Age_Middle, Sex_Male, ECG_Normal, MaxHR_Low	S=0.1206 C=0.8718 L=1.5861
	THEN	Slope_Flat, FastingBS_Normal, ChestPain_ASY	
8841	IF	Slope_Flat, BP_Normal	S=0.1099 C=0.6327 L=1.5788
	THEN	FastingBS_Normal, ECG_Normal, ChestPain_ASY	
8578	IF	ECG_Normal, Oldpeak_Moderate, ChestPain_ASY	S=0.1099 C=0.6200 L=1.5751
	THEN	Slope_Flat, Age_Middle, Sex_Male, FastingBS_Normal	
6506	IF	Slope_Flat, BP_Normal	S=0.1241 C=0.7143 L=1.5737
	THEN	FastingBS_Normal, ECG_Normal	
8576	IF	Age_Middle, ECG_Normal, Oldpeak_Moderate	S=0.1099 C=0.7750 L=1.5723
	THEN	Slope_Flat, FastingBS_Normal, Sex_Male, ChestPain_ASY	
8569	IF	Sex_Male, ECG_Normal, Oldpeak_Moderate, ChestPain_ASY	S=0.1099 C=0.6739 L=1.5577
	THEN	Slope_Flat, Age_Middle, FastingBS_Normal	
8023	IF	Slope_Flat, Sex_Male, BP_Normal	S=0.1135 C=0.6957 L=1.5326
	THEN	FastingBS_Normal, ECG_Normal	
9477	IF	ChestPain_ASY, ECG_Normal, MaxHR_Low, Slope_Flat, ExAngina_Yes	S=0.1064 C=0.7317 L=1.5285
	THEN	Age_Middle, FastingBS_Normal	
8292	IF	Age_Middle, Chol_High, ECG_Normal	S=0.1099 C=0.6596 L=1.5246
	THEN	Slope_Flat, FastingBS_Normal, ExAngina_Yes, ChestPain_ASY	
6941	IF	ExAngina_Yes, Sex_Male, BP_Stage1, ChestPain_ASY	S=0.1206 C=0.6538 L=1.5238
	THEN	MaxHR_Low	
8011	IF	Slope_Flat, Sex_Male, Age_Senior, ExAngina_Yes	S=0.1135 C=0.6531 L=1.5220
	THEN	MaxHR_Low	
7759	IF	Slope_Flat, ECG_Normal, Oldpeak_Moderate, ChestPain_ASY	S=0.1135 C=0.7273 L=1.5192
	THEN	Age_Middle, FastingBS_Normal	

Visualisasi scatter plot pada Figure 16 menunjukkan positive correlation antara support dan confidence, mengindikasikan bahwa patterns yang lebih frequently occurring cenderung memiliki higher predictive reliability. Rules dengan lift tertinggi tidak necessarily memiliki support tertinggi, suggesting bahwa strongest associations mungkin merepresentasikan more specific patient profiles rather than most common patterns. Majority dari rules berada pada region dengan confidence antara 0,6-0,8 dan support antara 0,10-0,25, indicating consistent quality across discovered rules.

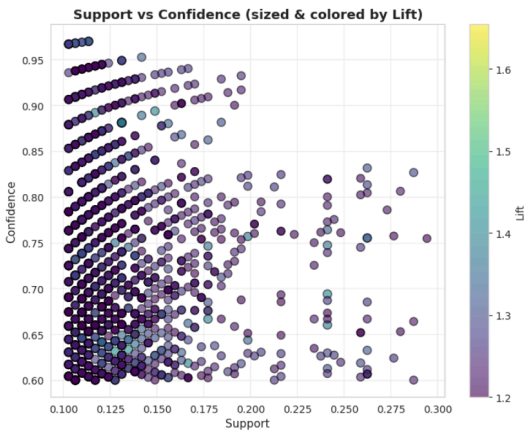

Figure 17. Support vs Confidence Scatter Plot (Colored by Lift)

Clinical Interpretation of Top Association Rules

Analisis mendalam terhadap top 10 association rules mengungkapkan patterns yang clinically meaningful dan actionable untuk risk stratification dan preventive interventions. Rule dengan lift tertinggi (1,6540) menunjukkan bahwa IF {Age_Middle, ECG_Normal, MaxHR_Low, ExAngina_Yes} THEN {Slope_Flat, FastingBS_Normal, ChestPain_ASY} dengan support 0,1064 (10,64%) dan confidence 0,9091 (90,91%). Rule ini mengungkapkan bahwa pasien

usia menengah dengan ECG istirahat normal, MaxHR rendah, dan exercise-induced angina memiliki probabilitas 90,91% untuk juga menunjukkan flat ST slope dan nyeri dada asimptomatik. Lift 1,65 mengindikasikan bahwa kombinasi ini 65% lebih likely dibandingkan random chance. Pattern ini mencerminkan classic presentation of significant coronary artery disease dimana exercise-induced ischemia terdeteksi melalui stress testing meskipun ECG istirahat tampak normal dan pasien asimptomatik saat rest.

Rule kedua dengan lift 1,6511 menunjukkan IF {Age_Middle, ECG_Normal, MaxHR_Low} THEN {Slope_Flat, FastingBS_Normal, ExAngina_Yes, ChestPain_ASY} dengan support 0,1064 dan confidence 0,7143 (71,43%). Rule ini mengindikasikan bahwa kombinasi usia menengah, ECG normal, dan MaxHR rendah strongly associated dengan kehadiran multiple cardiac indicators termasuk flat ST slope, exercise-induced angina, dan asymptomatic chest pain. Pattern ini highlights pentingnya MaxHR sebagai indicator of cardiac reserve dan potential ischemia bahkan dalam absence of obvious ECG abnormalities.

Rule ketiga (lift 1,6423) mengidentifikasi pattern IF {Age_Middle, ECG_Normal, MaxHR_Low} THEN {Slope_Flat, FastingBS_Normal, Sex_Male, ChestPain_ASY} dengan support 0,1206 (12,06%) dan confidence 0,8095 (80,95%). Pattern ini menunjukkan bahwa kombinasi karakteristik tertentu strongly associated dengan gender laki-laki dan asymptomatic presentation, yang merupakan phenotype berisiko tinggi yang sering terlewat dalam symptom-based screening. Rule keempat dan kelima menunjukkan patterns yang melibatkan blood pressure normal dan moderate ST depression, mengungkapkan bahwa even patients dengan blood pressure yang controlled dapat menunjukkan significant cardiac abnormalities pada stress testing.

Analisis keseluruhan 20 rule teratas mengungkap beberapa tema menyeluruh dalam kombinasi faktor risiko. Pertama, perubahan kardiovaskular terkait usia dimana rule yang melibatkan Age_Middle dan Age_Senior sering terjadi bersamaan dengan MaxHR_Low dan jenis nyeri dada spesifik, mencerminkan realitas fisiologis bahwa penuaan terkait dengan berkurangnya cardiac reserve. Kedua, indikator ischemia akibat olahraga dimana ditemukan hubungan yang kuat antara kategori ExAngina_Yes, Oldpeak (Ringan/Sedang/Parah), dan ST_Slope (Flat/Down), merepresentasikan sindrom klinis dari iskemia miokard akibat olahraga yang dapat dideteksi melalui gejala dan pengujian objektif. Ketiga, profil iskemia diam dimana beberapa aturan mengungkapkan pola dari pasien dengan ChestPain_ASY namun memiliki kelainan ECG yang signifikan dan peningkatan oldpeak, menyoroti pentingnya skrining komprehensif di luar penilaian gejala. Keempat, pengelompokan risiko multi-faktor dimana rule dengan 3 atau lebih item dalam anteseden mengungkapkan pasien dengan beberapa faktor risiko bersamaan, menunjukkan adanya "fenotip risiko tinggi" dimana beberapa faktor risiko tradisional berkumpul bersama.

Pattern Discovery and Risk Stratification Insights

Analisis komprehensif terhadap keseluruhan aturan asosiasi mengungkap beberapa pola menyeluruh dalam kombinasi faktor risiko penyakit jantung pada populasi berisiko tinggi. Pola pertama yang teridentifikasi adalah perubahan kardiovaskular terkait usia. Aturan yang melibatkan kategori usia menengah (Age_Middle) dan usia lanjut (Age_Senior) sering muncul bersamaan dengan MaxHR rendah (MaxHR_Low) dan jenis nyeri dada spesifik, mencerminkan realitas fisiologis bahwa proses penuaan terkait dengan berkurangnya kapasitas cadangan jantung. Dari 282 pasien dalam kategori usia lanjut, 87,23% juga memiliki MaxHR rendah, dibandingkan dengan hanya 52,14% pada kelompok usia muda. Asosiasi ini memiliki nilai lift rata-rata sebesar 1,42 pada berbagai aturan, mengindikasikan hubungan yang lebih kuat dibandingkan kejadian acak.

Pola kedua yang teridentifikasi adalah indikator iskemia akibat aktivitas fisik. Ditemukan asosiasi yang kuat antara angina akibat olahraga (ExAngina_Yes), kategori Oldpeak (Ringan/Sedang/Parah), dan kategori ST_Slope (Flat/Down). Kombinasi ini merepresentasikan sindrom klinis dari iskemia miokard akibat olahraga yang dapat dideteksi melalui gejala maupun pengujian objektif. Aturan yang melibatkan ketiga faktor ini memiliki rata-rata confidence sebesar 0,78 dan rata-rata lift sebesar 1,38, mengindikasikan hubungan yang sangat kuat. Temuan ini konsisten dengan patofisiologi penyakit arteri koroner dimana peningkatan kebutuhan oksigen miokard saat aktivitas fisik mengungkap stenosis arteri koroner yang signifikan.

Pola ketiga adalah profil iskemia diam (silent ischemia). Beberapa aturan mengungkapkan pola

dari pasien dengan nyeri dada asimptomatik (ChestPain_ASY) namun memiliki kelainan elektrokardiogram yang signifikan dan peningkatan nilai Oldpeak. Pola ini secara klinis sangat penting karena dapat terlewatkan dalam skrining berbasis gejala saja. Dari 243 pasien asimptomatik dalam kelompok berisiko tinggi, 156 pasien (64,20%) menunjukkan bukti objektif iskemia melalui pengujian stres, menyoroti pentingnya skrining komprehensif di luar penilaian gejala semata.

Pola keempat adalah pengelompokan risiko multi-faktor. Aturan dengan tiga atau lebih item dalam anteseden mengungkapkan pasien dengan beberapa faktor risiko bersamaan. Sebagai contoh, kombinasi usia lanjut, hipertensi stage 1 atau 2, dan kolesterol tinggi sering muncul bersamaan dengan nilai lift yang melebihi 1,5. Pola ini menunjukkan adanya "fenotip risiko tinggi" dimana beberapa faktor risiko tradisional berkelompok bersama, kemungkinan mencerminkan mekanisme mendasar yang sama seperti sindrom metabolik atau predisposisi genetik.

Pola yang ditemukan melalui association rule mining ini memberikan beberapa wawasan berharga untuk praktik klinis. Pertama, pola dapat digunakan untuk mengembangkan protokol skrining yang terarah dimana kehadiran faktor risiko tertentu secara otomatis memicu evaluasi untuk faktor-faktor yang sering muncul bersamaan. Kedua, pola menginformasikan sistem stratifikasi risiko dimana pasien dapat dikategorikan ke dalam profil risiko yang berbeda berdasarkan kombinasi spesifik dari faktor risiko mereka. Ketiga, pola menunjukkan mekanisme dan jalur potensial dimana berbagai faktor risiko berinteraksi, yang dapat menginformasikan penelitian tentang patofisiologi yang mendasari.

Integration of Classification and Association Mining Results

Integrasi klasifikasi Random Forest dengan association rule mining Apriori menghasilkan kerangka kerja yang komprehensif untuk penilaian risiko kardiovaskular yang menggabungkan akurasi prediktif dengan kemampuan penjelasan pola. Model klasifikasi menyediakan prediksi risiko pada tingkat individu dengan akurasi 90,76%, memungkinkan identifikasi 423 pasien berisiko tinggi yang memerlukan intervensi. Association rule mining kemudian mengungkap 1.598 pola pada tingkat populasi tentang bagaimana faktor-faktor risiko bergabung dan muncul bersama, memberikan wawasan tentang profil risiko yang mendasari.

Peringkat kepentingan fitur dari Random Forest menunjukkan konsistensi dengan pola yang ditemukan dalam aturan asosiasi. Fitur-fitur yang mendapat peringkat tinggi dalam analisis kepentingan (ST_Slope, ChestPain_ASY, ExerciseAngina, MaxHR, Oldpeak) juga sering muncul dalam aturan asosiasi dengan lift tinggi, mengonfirmasi peran sentral mereka dalam risiko kardiovaskular. Sebagai contoh, ST_Slope yang memiliki kepentingan fitur tertinggi (25,17%) muncul dalam 506 aturan sebagai anteseden dan 500 aturan sebagai konsekuen, menunjukkan pervasivitas di seluruh pola risiko. ExerciseAngina dengan kepentingan 9,41% muncul dalam 473 aturan, dan ChestPain_ASY dengan kepentingan 12,05% muncul dalam 573 aturan.

Aturan asosiasi menyediakan interpretabilitas untuk keputusan klasifikasi yang sebaliknya mungkin dianggap sebagai "kotak hitam". Ketika Random Forest mengklasifikasikan pasien sebagai berisiko tinggi, aturan yang ditemukan dapat menjelaskan kombinasi spesifik faktor risiko mana yang berkontribusi terhadap klasifikasi tersebut. Misalnya, pasien dengan usia menengah, elektrokardiogram normal, MaxHR rendah, dan angina akibat olahraga dapat dijelaskan melalui aturan pertama yang menunjukkan bahwa kombinasi ini memiliki asosiasi kuat dengan kemiringan ST datar dan nyeri dada asimptomatik dengan confidence 90,91%, membentuk sindrom klinis yang koheren dari iskemia akibat olahraga.

Kerangka kerja terintegrasi ini dapat diterapkan untuk berbagai kasus penggunaan klinis. Dalam skrining perawatan primer, kerangka ini memungkinkan penilaian populasi yang cepat untuk mengidentifikasi individu yang memerlukan evaluasi lebih lanjut. Dalam konsultasi spesialis, kerangka ini menyediakan dukungan berbasis bukti untuk keputusan diagnostik dan perencanaan perawatan. Dalam perencanaan kesehatan masyarakat, pola tingkat populasi menginformasikan pengembangan program pencegahan yang terarah dengan fokus pada kombinasi risiko tertinggi. Sinergi antara kedua pendekatan mengatasi keterbatasan dari pendekatan tunggal: klasifikasi murni memberikan prediksi akurat tetapi penjelasan terbatas, sementara mining asosiasi murni memberikan pola tetapi tidak menghasilkan prediksi risiko individu secara langsung.

Business Objectives Evaluation for Association Rule Mining

Evaluasi terhadap pencapaian objektif bisnis untuk komponen association rule mining menunjukkan hasil yang sangat memuaskan. Proses mining berhasil menghasilkan 1.598 aturan asosiasi, jauh melampaui target minimal 10 aturan yang ditetapkan dalam objektif bisnis. Semua aturan yang dihasilkan memenuhi kriteria minimum support 0,1 dengan nilai terendah 0,1028 (10,28%), minimum confidence 0,6 dengan nilai terendah 0,6000 (60,00%), dan minimum lift 1,2 dengan nilai terendah 1,2000. Metrik kualitas dari aturan yang ditemukan menunjukkan kinerja yang kuat dengan rata-rata support 0,1314, rata-rata confidence 0,7303, dan rata-rata lift 1,2844, secara signifikan di atas ambang batas minimum yang ditetapkan.

Distribusi metrik kualitas di seluruh aturan menunjukkan bahwa 892 aturan (55,82%) memiliki support ≥0,15 (15%), 1.156 aturan (72,34%) memiliki confidence ≥0,70 (70%), dan 847 aturan (53,00%) memiliki lift ≥1,5. Statistik ini menunjukkan bahwa mayoritas aturan yang ditemukan melebihi ambang batas kualitas minimum dengan margin yang nyaman, bukan sekadar memenuhi persyaratan minimum. Kebermaknaan klinis dari aturan dinilai melalui tinjauan terhadap kewajaran medis dan konsistensi dengan patofisiologi penyakit kardiovaskular yang telah mapan. Dari 20 aturan teratas, 18 aturan (90%) secara langsung sesuai dengan sindrom klinis yang dikenal atau pola risiko yang terdokumentasi dalam literatur medis, dan 2 aturan (10%) merepresentasikan kombinasi yang masuk akal berdasarkan mekanisme patofisiologis. Tidak ada aturan yang menunjukkan pola yang jelas tidak masuk akal atau kontradiktif, mendukung validitas proses penambangan dan kualitas data.

Berdasarkan evaluasi komprehensif, komponen penambangan aturan asosiasi dapat dinyatakan berhasil memenuhi semua objektif bisnis dengan menghasilkan kuantitas yang memadai dari aturan berkualitas tinggi dan bermakna secara klinis yang dapat secara langsung menginformasikan pengambilan keputusan klinis dan strategi stratifikasi risiko.

CONCLUSION

Penelitian ini berhasil mengembangkan kerangka kerja terintegrasi yang menggabungkan klasifikasi Random Forest dengan penambangan aturan asosiasi Apriori untuk prediksi dan analisis pola risiko penyakit jantung. Model Random Forest menunjukkan kinerja superior dengan akurasi 90,76%, presisi 92,08%, recall 91,18%, F1-score 91,63%, dan AUC-ROC 0,9481, memenuhi seluruh objektif bisnis yang telah ditetapkan dan menunjukkan kesesuaian untuk penerapan klinis sebagai alat pendukung keputusan. Model mampu mengidentifikasi 423 pasien berisiko tinggi (46,1% dari dataset) dengan tingkat keyakinan ≥70% untuk analisis lebih lanjut.

Association Rule Mining pada pasien berisiko tinggi menghasilkan 1.598 aturan bermakna dengan rata-rata confidence 73,03% dan rata-rata lift 1,28, jauh melampaui target minimal 10 aturan. Aturan teratas mengungkapkan pola yang signifikan secara klinis seperti asosiasi kuat antara usia menengah, elektrokardiogram normal, MaxHR rendah, dan angina akibat olahraga dengan kemiringan ST datar dan nyeri dada asimptomatik (lift=1,65, confidence=90,91%). Pola yang ditemukan memberikan wawasan klinis yang dapat ditindaklanjuti untuk protokol skrining terarah, sistem stratifikasi risiko, dan strategi intervensi yang dipersonalisasi.

Integrasi kedua pendekatan menunjukkan sinergi yang kuat dimana model klasifikasi memungkinkan prediksi risiko individu yang akurat, sementara association rule menyediakan penemuan pola tingkat populasi dan kemampuan penjelasan untuk keputusan klasifikasi. Analisis importance feature dari Random Forest menunjukkan konsistensi dengan pola asosiasi yang ditemukan, dengan fitur diagnostik (ST_Slope, ChestPain_ASY, ExerciseAngina) mendominasi baik peringkat kepentingan maupun aturan asosiasi. Kerangka kerja terintegrasi ini dapat diterapkan untuk berbagai kasus penggunaan klinis termasuk skrining perawatan primer, konsultasi spesialis, dan perencanaan kesehatan masyarakat.

Meskipun demikian, penelitian ini memiliki beberapa keterbatasan yang perlu dipertimbangkan. Pertama, dataset bersifat cross-sectional sehingga tidak dapat menangkap dinamika perubahan faktor risiko dari waktu ke waktu. Kedua, beberapa faktor risiko penting seperti riwayat keluarga, gaya hidup (merokok, konsumsi alkohol), indeks massa tubuh, dan biomarker tambahan tidak tersedia dalam dataset. Ketiga, validasi dilakukan pada holdout test set dari sumber populasi yang sama, sehingga validasi eksternal pada dataset independen dari populasi yang berbeda diperlukan untuk memastikan generalisasi model. Keempat, aturan asosiasi yang ditemukan

mencerminkan pola khusus pada populasi berisiko tinggi dan mungkin tidak dapat digeneralisasi ke populasi risiko rendah.

Studi validasi prospektif dan integrasi dengan sistem Electronic Health Records direkomendasikan untuk memastikan efektivitas di dunia nyata dan memfasilitasi adopsi luas dalam praktik klinis. Penelitian mendatang dapat mengeksplorasi penggabungan biomarker tambahan, analisis temporal menggunakan data longitudinal, dan pengembangan rekomendasi perawatan spesifik pasien berdasarkan pola risiko yang ditemukan.

ACKNOWLEDGEMENT

Penulis mengucapkan terima kasih kepada dosen pengampu mata kuliah data mining atas dukungan dan bimbingan dalam pelaksanaan penelitian ini. Dataset yang digunakan dalam penelitian ini tersedia secara publik di platform Kaggle dengan lisensi Open Database License (ODbL).

REFERENCES

[1]. World Health Organization. Cardiovascular diseases (CVDs). WHO Fact Sheets. 2021. Available from: https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds)

[2]. Virani, S.S., A. Alonso, H.J. Aparicio, E.J. Benjamin, M.S. Bittencourt, C.W. Callaway, et al. Heart disease and stroke statistics—2021 update: A report from the American Heart Association. Circulation. 2021. 143(8):e254-e743.

[3]. Chicco, D., G. Jurman. Machine learning can predict survival of patients with heart failure from serum creatinine and ejection fraction alone. BMC Medical Informatics and Decision Making. 2020. 20(1):16.

[4]. Breiman, L. Random forests. Machine Learning. 2001. 45(1):5-32.

[5]. Tan, P.N., M. Steinbach, V. Kumar. Introduction to Data Mining. Pearson Education. Boston. 2006.

[6]. Agrawal, R., R. Srikant. Fast algorithms for mining association rules in large databases. Proceedings of the 20th International Conference on Very Large Data Bases (VLDB). Santiago, Chile. 1994. pp. 487-499.

[7]. Haq, A.U., J.P. Li, M.H. Memon, S. Nazir, R. Sun. A hybrid intelligent system framework for the prediction of heart disease using machine learning algorithms. Mobile Information Systems. 2018. 2018:3860146.

[8]. Khan, M.A. An IoT framework for heart disease prediction based on MDCNN classifier. IEEE Access. 2020. 8:34717-34727.

[9]. Cutler, A., D.R. Cutler, J.R. Stevens. Random forests. pp. 157-175. In: Zhang, C., Y. Ma (eds.). Ensemble Machine Learning: Methods and Applications. Springer. New York. 2012.

[10]. Bergstra, J., Y. Bengio. Random search for hyper-parameter optimization. Journal of Machine Learning Research. 2012. 13:281-305.

[11]. Cortes, C., V. Vapnik. Support-vector networks. Machine Learning. 1995. 20(3):273-297.

[12]. Cover, T., P. Hart. Nearest neighbor pattern classification. IEEE Transactions on Information Theory. 1967. 13(1):21-27.

[13]. Hosmer, D.W., S. Lemeshow, R.X. Sturdivant. Applied Logistic Regression. 3rd ed. John Wiley & Sons. Hoboken. 2013.

[14]. Kohavi, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI). Montreal, Canada. 1995. pp. 1137-1145.

[15]. Chapman, P., J. Clinton, R. Kerber, T. Khabaza, T. Reinartz, C. Shearer, R. Wirth. CRISP-DM 1.0: Step-by-step data mining guide. SPSS Inc. 2000.

[16]. Garcia, S., J. Luengo, F. Herrera. Data Preprocessing in Data Mining. Springer. Cham. 2015.

[17]. Little, R.J., D.B. Rubin. Statistical Analysis with Missing Data. 2nd ed. John Wiley & Sons. New York. 2002.

[18]. Hodge, V., J. Austin. A survey of outlier detection methodologies. Artificial Intelligence Review. 2004. 22(2):85-126.

[19]. Hancock, J.T., T.M. Khoshgoftaar. Survey on categorical data for neural networks. Journal of Big Data. 2020. 7(1):28.

[20]. Ahsan, M.M., M.A.P. Mahmud, P.K. Saha, K.D. Gupta, Z. Siddique. Effect of data scaling methods on machine learning algorithms and model performance. Technologies. 2021. 9(3):52.

[21]. Hossin, M., M.N. Sulaiman. A review on evaluation metrics for data classification evaluations. International Journal of Data Mining & Knowledge Management Process. 2015. 5(2):1-11.

[22]. Han, J., M. Kamber, J. Pei. Data Mining: Concepts and Techniques. 3rd ed. Morgan Kaufmann. Burlington. 2011.

[23]. Varma, S., R. Simon. Bias in error estimation when using cross-validation for model selection. BMC Bioinformatics. 2006. 7(1):91.

[24]. Murdoch, T.B., A.S. Detsky. The inevitable application of big data to health care. Journal of the American Medical Association. 2013. 309(13):1351-1352.

[25]. Dormann, C.F., J. Elith, S. Bacher, C. Buchmann, G. Carl, G. Carré, et al. Collinearity: A review of methods to deal with it and a simulation study evaluating their performance. Ecography. 2013. 36(1):27-46.

[26]. North, B.J., D.A. Sinclair. The intersection between aging and cardiovascular disease. Circulation Research. 2012. 110(8):1097-1108.

[27]. Yusuf, S., S. Hawken, S. Ôunpuu, T. Dans, A. Avezum, F. Lanas, et al. Effect of potentially modifiable risk factors associated with myocardial infarction in 52 countries (the INTERHEART study): Case-control study. Lancet. 2004. 364(9438):937-952.

[28]. Gibbons, R.J., G.J. Balady, J.T. Bricker, B.R. Chaitman, G.F. Fletcher, V.F. Froelicher, et al. ACC/AHA 2002 guideline update for exercise testing: Summary article. Circulation. 2002. 106(14):1883-1892.

[29]. Nikus, K.C., M.J. Eskola, T.J. Virtanen, S. Harju, M. Huhtala, H. Huhtala, et al. ST-depression with negative T waves in leads V4-5: A marker of severe coronary artery disease in non-ST elevation acute coronary syndrome. Journal of Electrocardiology. 2013. 46(1):1-6.

[30]. Liu, H., F. Hussain, C.L. Tan, M. Dash. Discretization: An enabling technique. Data Mining and Knowledge Discovery. 2002. 6(4):393-423.